

1. 目标分布的定义

我们以教师策略为先验、以任务奖励为“类似然”构造目标序列分布

$$\pi^*(y|x) \propto \pi_T(y|x)^\lambda \exp(\beta r(x, y))$$

其中 λ 控制先验强度， β 控制奖励强度。写成对数形式为

$$\log \pi^*(y|x) = \lambda \log \pi_T(y|x) + \beta r(x, y) - \log Z(x),$$

($Z(x)$) 为归一化常数。

与贝叶斯的关系： 若将 $\pi_T(\cdot|x)^\lambda$ 视为先验 $p(y|x)$ ，并以

$$p(o=1|x, y) \propto \exp(\beta r(x, y))$$

建模“好结果被观察到”，则 Bayes 定理给出

$$p(y|x, o=1) \propto p(y|x)p(o=1|x, y) \propto \pi_T(y|x)^\lambda \exp(\beta r(x, y)),$$

2. 学习目标：投影到 π^*

给定训练输入分布 $\mathcal{D}(x)$ ，我们希望学生策略在每个 x 上逼近 $\pi^*(\cdot|x)$ 。

$$\mathcal{J}(\theta) = \mathbb{E}_{x \sim \mathcal{D}} [\text{KL}(\pi^*(\cdot|x) || \pi_\theta(\cdot|x))] = -\mathbb{E}_{x \sim \mathcal{D}, y \sim \pi^*(x)} [\log \pi_\theta(y|x)] + \text{const.}$$

该选择使得学生“覆盖” π^* 的模式（mode-covering），有利于保持多样性。

3. 前向 KL 的 on-policy 估计（序列级）

$$\nabla_\theta \mathcal{J}(\theta) = -\mathbb{E}_x \mathbb{E}_{y \sim \pi^*(\cdot|x)} [\nabla_\theta \log \pi_\theta(y|x)].$$

由于无法直接从 π^* 采样，采用学生策略 π_θ 的 on-policy 自归一化重要性采样：

对固定的 x ，令

$$\log \tilde{w}(x, y) = \lambda \log \pi_T(y|x) + \beta r(x, y) - \log \pi_\theta(y|x).$$

给定样本 $y^{(k)} \sim \pi_\theta(\cdot|x)$ ，令

$$\hat{w}^{(k)} = \frac{\exp(\log \tilde{w}^{(k)} - c)}{\sum_j \exp(\log \tilde{w}^{(j)} - c)} \quad (\text{如 } c = \max_j \log \tilde{w}^{(j)}),$$

则单个 x 的梯度估计为

$$\widehat{\nabla_{\theta} \mathcal{J}}(x) = - \sum_{k=1}^K \hat{w}^{(k)} \nabla_{\theta} \log \pi_{\theta} \left(y^{(k)} | x \right),$$

再跨 x 取平均。实现时对 $\hat{w}^{(k)}$ 停止梯度。

将整序列对数概率写成 **token** 和：

$$\log \pi_{\theta}(y^{(k)} | x) = \sum_{t=1}^{T_k} \log \pi_{\theta} \left(y_t^{(k)} | x, y_{<t}^{(k)} \right),$$

所以梯度可拆成 **token** 和：

$$\widehat{\nabla_{\theta} \mathcal{J}}(x) = - \sum_{k=1}^K \hat{w}^{(k)} \sum_{t=1}^{T_k} \nabla_{\theta} \log \pi_{\theta} \left(y_t^{(k)} | x, y_{<t}^{(k)} \right).$$

1. 先按序列算出权重：

$$\log \tilde{w}^{(k)} = \lambda \sum_t \log \pi_T(\cdot) - \sum_t \log \pi_{\theta}(\cdot) + \beta r^{(k)},$$

做 **softmax** 得到 $\hat{w}^{(k)}$ （停用梯度）。

2. 损失写成 **token** 交叉熵带序列权重：

$$L = - \sum_{k=1}^K \hat{w}^{(k)} \sum_{t=1}^{T_k} \log \pi_{\theta} \left(y_t^{(k)} | x, y_{<t}^{(k)} \right).$$